


Part 2. 인공지능 이론

인공지능 역사

인공지능 기술은 인간의 지능을 기계 등에 인공적으로 구현하려는 기술로, 부흥기 / 침체기를 반복해왔다.



그림출처:<https://itwiki.kr/w/인공지능>

연도	이벤트
1950	- 앨런 튜링이 논문 "Computing Machinery And Intelligence"에서 AI라는 아이디어를 처음 제시 "기계는 생각할 수 있는가?"라는 질문을 던지며 기계가 AI를 가졌는지 판단하는 튜링 테스트를 제시
1956	다트머스 학회에서 존 매카시가 AI를 "인간들만 풀 수 있던 문제를 풀고 스스로 발전해 나가는 존재"로 정의하고 사용하기 시작
1957	프랑크 로젠블라트가 (로지스틱 회귀의 초기 버전으로 볼 수 있는) 퍼셉트론을 발표
1959	아서 사무엘 박사가 "명시적으로 프로그램을 하지 않고도 컴퓨터가 학습할 수 있는 능력을 갖는다"는 의미로 머신러닝이란 용어를 사용
1960말	마빈 민스키와 시모어 페퍼트가 퍼셉트론(단층 신경망)의 한계를 지적 (기호와 논리의 XOR 문제를 구현할 수 없다는 것을 수학적으로 증명, 추후 다중 퍼셉트론으로 극복)
1980년대	- 기계에게 세상의 지식을 학습시키는 방식으로 전문가 시스템 구현 - 프레임 문제와 심볼 그라운드링 문제 대두
1986	제프리 힌턴 교수가 역전파 알고리즘으로 다층 인공 신경망을 학습시키는데 성공
2000년대 중반이후	데이터 전처리 과정의 개발과 GPU의 활용, 그리고 빅데이터의 탄생과 함께 다시 급속도로 발전
2012	제프리 힌턴 교수팀이 이미지 분류 대회인 ImageNet에서 기존의 머신러닝 방법을 누르고 압도적인 성능으로 우승하며 딥러닝 시대가 열림, 다양한 분야에 인공지능 기술 접목 중

현재 수준 | 인공지능 기술 | 생성형 AI에서 Agentic AI로 확장

생성형 인공지능은 대규모 언어모델(LLM)과 멀티모달 모델을 기반으로 텍스트, 이미지, 음성, 코드 등 다양한 형태의 콘텐츠를 생성·분석하는 기술이다.

ChatGPT, Claude Code, Gemini, DeepSeek 등은 질의응답, 문서 작성, 검색, 코딩, 분석 자동화 등 다양한 작업에서 활용되고 있다.

기능	 ChatGPT	 Claude Code	 Gemini	 deepseek
개발사	OpenAI	Anthropic	Google DeepMind	DeepSeek AI
대표 모델	GPT- 4.1 / 4o	Claude 4 기반	Gemini 2.5	DeepSeek-V3/R1
아키텍처	Transformer 기반	코딩 에이전트형 워크플로	멀티모달 Transformer	Mixture-of-Experts
주요 기능	대화, 문서작성, 코딩	코드분석, 파일수정, 명령실행, 테스트 자동화	대화,검색, 이미지·영상이해, 코딩지원	추론, 코딩, 기술업무
강점	범용성·창의성·문서화	비용 효율성 코딩·추론	멀티모달 처리 Google 검색연계	비용 효율성, 코딩·추론

출처 : <https://1seo.com/blog/deepseek-vs-chatgpt-which-ai-tool-is-right-for-your-business>

사례 영상 : 대규모 언어모델 (LLM)과 ChatGPT



영상출처:<https://www.youtube.com/watch?v=HnvitMTkXro>

현재 수준 인공지능 기술 | 프롬프트 엔지니어링 vs. 하네스 엔지니어링

AI의 활용은 **프롬프트, 컨텍스트, 하네스 엔지니어링**으로 발전하였다. 초기의 사용자가 좋은 질문을 만들어 AI의 답변 품질을 높이는 것에서 문서, 규칙, 예시, 업무의 맥락을 제공하여 정확하게 하는 컨텍스트 설계로, 최근에는 AI가 질문 받은 답변을 생성하는 수준을 넘어, 각자 역할을 나누고 작업 흐름을 설계하고 실행 결과를 검증하는 **하네스 엔지니어링** 단계로 변화하였다.



하네스 엔지니어링

하네스 엔지니어링은 AI가 일하는 시스템을 설계하는 것으로 각자의 역할과 전문성을 부여받은 **에이전트**와 에이전트가 실행할 **스킬·도구**, 에이전트의 작업 흐름을 조율하는 **오케스트레이터**, 작업결과를 평가·테스트하며 상태를 기록하고 개선하는 **아티팩트·메모리**로 구성된다.



출처 : <https://www.youtube.com/watch?v=iqoPgoYBVaM>

현재 인공지능 기술 | 인공지능 비서 수준


현재 인공지능 기술은 인공지능 스피커/챗봇/각종 AI알고리즘 기반 가전제품 등 우리 생활 전반에 널리 활용되고 있다.

그 중에서도 인공지능 비서(Intelligent personal assistant)는 음성인식부터 지식추론에 이르기까지 다양한 인공지능 기반기술을 포함하며, 애플 / MS / 구글 / 아마존 / 네이버 / 카카오 등 IT업계의 리더들이 모두 자신만의 인공지능 비서 서비스를 제공하고 있다.

기술 \ 분야	건강	모빌리티	금융	온라인 서비스	가정·개인
음성 인식 & 자연어 처리	원격 진료	음성 인식 명령	챗봇	챗봇	개인 비서
이미지 인식	원격 진료	교통 신호 인식	보안	보안	가정 로봇
패턴 인식	개별 건강 패턴	이동패턴	주식 추천	물품 추천	수면 패턴

[출처: Consumers International, Artificial Intelligence: consumer experiences in new technology - RESEARCH AND WORKSHOP REPORT APRIL 2019]


사례 영상 (Apple Intelligence)



영상출처:<https://youtu.be/PugKQZHPut8?si=MHItxGVsRDo8G7qR>

현재 인공지능 기술 | 자율주행차

자율주행 역시 기계의 인지 / 판단 / 제어가 복합적으로 요구되는 기술로, 완전 자율주행이 가능하기 까지는 차량 자체의 기술발전 뿐만 아니라 도로 인프라, 법률과 제도 개선 등 고려되어야 할 사항이 많다.



자율주행 기술 단계별 분류

시스템이 **일부 주행**을 수행 (주행 책임:운전자)

Level 0 비자동화		Hands On 운전자 항상 운행 긴급상황 시스템 보조
Level 1 운전자 보조		Hands On 시스템이 조향 또는 감/가속 보조
Level 2 부분자동화		Hands Off 시스템이 조향 및 감/가속 수행

시스템이 **전체 주행**을 수행 (주행 책임:시스템)

Level 3 조건부자동화		Eyes Off 위험 시 운전자 개입
Level 4 고등자동화		Mind Off 운전자 개입 불필요
Level 5 완전자동화		Driver Off 운전자 불필요

● 운전자가 수행 ● 운전자가 조건부 수행 ● 시스템이 수행

자료: 미국 자동차 공학회

KBS


사례 영상 (Tesla)



영상출처:https://youtu.be/TUDiG7PcLBs?si=i8N8UZ_yHH3AB7Pc

현재 수준 인공지능 기술 | 예술 분야

딥러닝 기술 (특히 GAN 기술)의 발전으로 음악, 영상, 문학 등의 예술/창작 분야에서도 큰 성과를 내고 있다.



2021년 출간된 국내 최초의 인공지능 장편소설 '지금부터의 세계'와
2018년 뉴욕 크리스티 경매에서 5억원에 낙찰된 역사상 최초의 인공지능 작품이라 불리는 자화상

사례 영상

다빈치가 된 알고리즘




영상출처:<https://www.youtube.com/watch?v=Nou2jvqM-bY>

인공지능 개념 | 인공지능 (Artificial Intelligence)

인공지능 정의

인공지능이란 사람의 인식, 판단, 추론, 결론이라는 의사결정 프로세스와 학습이라는 기능을 인공적으로 실현할 수 있게 하는 컴퓨터 시스템을 말한다.



- 경험을 통해 학습하는 능력
- 이미 알고 있는 것을 바탕으로 새로운 것을 추론하는 능력
- 언어를 듣고 이해하는 능력
- 보거나 듣고 무엇인지 알아보는 능력
- 감정을 파악하고 공감하는 능력
- 정해진 규칙을 빠르고 정확하게 지치지 않고 수행하는 능력

인공지능과 지능형 에이전트

인공지능은 철학, 수학, 경제학, 신경과학, 심리학, 컴퓨터 공학, 제어 이론과 인공지능학, 언어학을 포함하는 매우 범위가 큰 학문으로, 인공지능이 해결하려는 문제는 다음을 포함한다.

탐색

제약 만족 문제

논리적 에이전트

계획 수립

지식 기반 시스템

확률적 추론

의사결정

머신러닝

자연어 처리

이러한 인공지능 능력을 가지고 환경, 사용자 입력 및 경험에 따라 결정을 내리거나 서비스를 수행하는 프로그램을 지능형 에이전트(인공지능 에이전트)라고 한다.

인공지능 개념 | 기계학습 (Machine Learning)

인공지능 vs. 기계학습

인공지능 에이전트는 행동이 제한된 세계 (ex: 게임 환경)에서는 '지능이 있다'고 여길 만한 능력을 보이기도 한다. 하지만 기하급수적인 복잡도를 가지는 현실세계에서는 인간과 같은 범용적인 문제 해결 능력을 갖지 못하는 한계를 보이게 되었다.

1990년대 초반까지 수십 년 동안 성과다운 성과가 거의 나오지 않았기 때문에, 대부분의 엔지니어들은 범용 Top-Down 추론 기계에 대한 환상을 버리고 좀 더 현실적인 과제에 집중하기 시작했다.

이런 실용주의적 태도 전환으로 인해 음성인식, 기계번역, 손글씨로 쓴 숫자를 인식하는 일과 같은 컴퓨터 비전 과제에서 진전을 이룰 수 있었다.

기호, 논리 기반

vs

데이터, 통계 기반

인간이 어떻게 말을 하고, 글을 읽고,
시각적 이미지를 처리하는지에 대한
수학적 모델을 먼저 만들고 나서
이런 작업들을 논리적으로 추론하는 프로그램
개발

수많은 데이터로부터
특정 문제 해결에 필요한
결정적인 특징을 파악하여
데이터에 기반하여 의사결정을 하는 것

기계학습 정의

"컴퓨터에게 배울 수 있는 능력, 즉 코드로 정의하지 않은 동작을 실행하는 능력에 대한 연구 분야"

- Arthur Samuel -

"만약 컴퓨터 프로그램이 특정한 태스크 T를 수행할 때 성능 P 만큼 개선되는 경험 E를 보이면 그
컴퓨터 프로그램은 태스크T와 성능 P에 대해 경험 E를 학습했다고 할 수 있다."

- Tom Michell -

체커 게임을 예로 들면,

태스크 (T) = 체커 게임을 두는 것

경험 (E) = 수없이 많은 게임을 두는 것

성능 (P) = 다음 게임에서 이길 확률

필기체 인식을 예로 들면,

태스크 (T) = 필기체를 정확한 문자로 인식하는 것

경험 (E) = 정답이 표시된 필기체

성능 (P) = 필기체를 정확히 인식할 확률


컴퓨터는 체커 게임에서 수많은 게임(T)을 통해서 경험(E)로부터 승리할 확률(P)를 스스로 향상시켰기에 기계가 학습했다고 할 수 있다.

인공지능 개념 | 데이터 과학 (Data Science)

데이터 과학

데이터 과학은 정형, 비정형 형태를 포함한 다양한 데이터로부터 지식과 인사이트를 추출하는 데 필요한 과학적 방법론, 프로세스, 알고리즘, 시스템을 동원하는 융합분야로 다음과 같은 기술 요소들을 포함한다.

- 데이터 획득과 데이터 통합
- 분산 아키텍처 상에서의 데이터 처리
- 데이터 엔지니어링, 시각화, 모델링




데이터 과학자 (Data Scientist)

데이터 과학자(데이터 사이언티스트)는 빅데이터의 세계에서 의미 있는 발견을 할 수 있도록 훈련된, 호기심을 가진 전문가라고 할 수 있으며, 다음과 같은 역량이 요구된다.

- 빅데이터에 대한 이론적 지식 : 관련 기법에 대한 이해와 방법론 습득
- 분석 기술에 대한 숙련: 최적의 분석 설계 및 노하우 축적
- 통찰력 있는 분석: 창의적 사고, 호기심, 논리적 비판
- 설득력 있는 전달: 스토리텔링, 시각화
- 다분야간 협력: 커뮤니케이션

인공지능 개념 | 인공지능과 관련기술 관계

인공지능 vs. 기계학습 vs. 데이터 과학



인공지능, 기계학습(인공신경망, 딥러닝), 데이터 과학 모두 빅데이터와 통계를 기반으로 한다는 공통점을 가진다.

데이터 과학이 가설을 검증하는 일과 밀접한 관계가 있는 반면, 기계학습은 가설을 통해 일반화한 프로세스를 시스템화 하는 데 초점을 맞추고 있다고 할 수 있다.

기계학습 vs. 데이터 마이닝

기계학습과 데이터 마이닝은 종종 같은 방법을 사용하며 상당히 중첩된다. 다만 다음에 따라 대략적으로 구분된다.


- 기계학습은 훈련 데이터(Training Data)를 통해 학습된 알려진 속성을 기반으로 '예측'에 초점을 두고 있다.
- 데이터 마이닝은 데이터의 알려지지 않았던 속성을 '발견'하는 것에 집중한다.

학습 대상

본 과정에서는 기계학습 알고리즘에 초점을 맞추어 학습을 진행한다.

기계학습 분류

기계학습 알고리즘은 일반적으로 지도학습, 비지도학습, 강화학습 등으로 분류된다. 이 분류는 데이터에 포함된 정보와 그 정보의 사용 방법에 따른 것이다.



지도학습

지도학습은 입력과 원하는 출력의 쌍이 모두 주어진 상태에서 학습하는 방법이다. 학습 후에는 새로운 입력에 해당하는 출력을 예측하는 데 사용한다.

비지도학습

비지도학습은 입력에 해당하는 바람직한 출력의 정보는 주어지지 않는다. 유사성을 기준으로 입력 집합을 군집화한다.

강화학습

강화 학습은 성공과 실패의 정보로부터 바람직한 행동 패턴을 스스로 학습하는 알고리즘이다. 강화 학습의 환경은 에이전트가 처할 수 있는 상태, 각 상태에서 선택할 수 있는 행동, 행동에 따른 상태의 변화, 그리고 보상으로 정의된다.


강화 학습은 입출력 쌍으로 이루어진 훈련데이터 집합이 제시되지 않는다는 점에서 지도학습과 다르고, 훈련데이터가 전혀 없는 것이 아니라 상황 종료 시에 종합적으로 주어진다는 점에서 비지도학습과도 다르다.

기계학습 알고리즘

지도 학습

위키백과, 우리 모두의 백과사전.

지도 학습 (Supervised Learning)은 훈련 데이터(Training Data)로부터 하나의 함수를 유추해내기 위한 **기계 학습**(Machine Learning)의 한 방법이다. 훈련 데이터는 일반적으로 입력 객체에 대한 속성을 벡터 형태로 포함하고 있으며 각각의 벡터에 대해 원하는 결과가 무엇인지 표시되어 있다. 이렇게 유추된 함수 중 연속적인 값을 출력하는 것을 **회귀분석**(Regression)이라 하고 주어진 입력 벡터가 어떤 종류의 값인지 표시하는 것을 **분류**(Classification)라 한다. 지도 학습기(Supervised Learner)가 하는 작업은 훈련 데이터로부터 주어진 데이터에 대해 예측하고자 하는 값을 올바르게 추측해내는 것이다. 이 목표를 달성하기 위해서는 학습기가 "알맞은" 방법을 통하여 기존의 훈련 데이터로부터 나타나지 않던 상황까지도 일반화하여 처리할 수 있어야 한다. 사람과 동물에 대응하는 심리학으로는 **개념 학습**(Concept Learning)을 예로 들 수 있다.




Supervised Learning Algorithms

회귀 (Regression)

회귀는 여러 개의 독립변수와 한 개의 종속변수 간의 상관관계를 모델링하는 기법을 통칭한다. 즉, 데이터가 주어졌을 때 데이터를 가장 잘 설명하는 함수를 찾아내고, 해당 함수를 통해 학습데이터에 있지 않았던 입력에 대한 출력을 예측한다.

대표적인 Regression 알고리즘

- 일반 선형 회귀 (Linear Regression)
- 규제화된 회귀 – Ridge, Lasso, ElasticNet




Regression Algorithms

분류 (Classification)


분류 문제의 학습은 학습 데이터를 잘 분류할 수 있는 함수(수학적 함수, 규칙, 패턴)를 찾는 것이다. 학습에 사용되지 않은 데이터에 대해서 분류를 잘 하는 일반화 능력이 좋은 모델을 이상적인 분류기로 평가할 수 있다.

대표적인 Classification 알고리즘

- 의사결정나무 (decision tree)
- 랜덤 포레스트 (random forest)
- KNN (K-nearest neighbor)
- SVM (Support Vector Machine)
- 다층 퍼셉트론 신경망
- 딥러닝 신경망



Decision Tree Algorithms



Deep Learning Algorithms

기계학습 알고리즘


비지도 학습

위키백과, 우리 모두의 백과사전.

비지도 학습(Unsupervised Learning)은 **기계 학습**의 일종으로, 데이터가 어떻게 구성되었는지를 알아내는 문제의 범주에 속한다. 이 방법은 **지도 학습**(Supervised Learning) 혹은 **강화 학습**(Reinforcement Learning)과는 달리 입력값에 대한 목표치가 주어지지 않는다.

자율 학습은 **통계의 밀도 추정**(Density Estimation)과 깊은 연관이 있다. 이러한 자율 학습은 데이터의 주요 특징을 요약하고 설명할 수 있다.

자율 학습의 예로는 **클러스터링**(Clustering)을 들 수 있다. 또 다른 하나의 예로는 **독립 성분 분석**(Independent Component Analysis)이 있다.




Unsupervised Learning Algorithms

군집화 (Clustering)

군집화 알고리즘의 기본 아이디어는 같은 군집에 속한 데이터와의 거리는 최소로 줄이고, 다른 군집에 있는 데이터와의 거리는 최대로 늘리는 것을 목표로 군집의 소속을 바꿔가면서 최적의 구성을 찾는 것이다. 군집화는 데이터의 구조 파악, 데이터의 Anomaly/Outlier 탐지, 데이터 전처리 등에 활용된다.

대표적인 Clustering 알고리즘

- K-means
- 계층적 군집화
- Gaussian Mixture Model
- DBSCAN (밀도기반 클러스터링)




Clustering Algorithms

차원 축소 (Dimensionality reduction)

차원 축소란 고차원의 데이터 정보의 손실을 최소화 하면서 저차원으로 변환하는 것이다. 차원 축소를 통해 데이터를 압축하여 모델 성능을 향상시키고 직관적인 데이터 분석을 가능하게 할 수 있다.

대표적인 차원 축소 알고리즘


- PCA (Principal Component Analysis, 주요 성분 분석)
- SVD (Singular Value Decomposition, 특이값 분해)
- NMF (Non-negative Matrix Factorization, 비음수 행렬 인수분해)



Dimensional Reduction Algorithms

기계학습 | 강화학습 알고리즘

강화 학습이란 매 상태에서 취할 수 있는 행동에 따른 누적 보상의 기댓값을 최대로 하는 행동 패턴을 배우는 것이다. 한 상태의 누적 보상 기댓값 계산에는 이 상태에서 출발한 모든 궤적을 고려해야 하는데 궤적의 수는 매우 많은 것이 일반적이다. 보상은 현재의 상태와 행동에 의하여 즉시 얻을 수 있는 이득으로 표현되지만 지능형 에이전트는 누적 보상을 최대화하는 행동 패턴을 학습해야 한다.



<https://opentutorials.org/course/4548/28949>

사례 영상

Basic Idea

$w_1 = 0.5$
 $w_2 = 0.05$
 $w_3 = 0.2$
 $w_n = 0.15$

The MoMP uses a weighted combination of primitive movements to generate new hitting strokes.

<https://www.youtube.com/watch?v=SH3bADiB7uQ>

기계학습 | 대표 라이브러리 알고리즘

Scikit-learn	Python 기반 SVM, Random Forest, KNN, PCA 등 다양한 알고리즘 제공 API가 직관적이고 일관성 있어 입문자부터 폭넓게 사용
TensorFlow	Python, C++ 기반 구글이 개발한 딥러닝 및 기계학습 프레임워크 GPU/TPU 가속으로 NN, CNN, RNN, 강화학습, 분포학습 지원
PyTorch	Python, C++ 기반 Meta가 개발한 동적계산 그래프 기반 딥러닝 프레임워크 직관적 코드 작성, Transformer, LSTM, GAN 모델 구현에 적합
Keras	Python 기반 TensorFlow 위에 구축한 고수준 딥러닝 API 빠른 모델 빌딩, 실험에 최적화, 초보자도 쉽게 이용


(실습) <https://scikit-learn.org/stable/index.html> 에 접속하여
하나의 알고리즘을 선택하여 개요/시각화 방법/구현 API 구조에 대해 자세히 살펴보기

 Student Notes

인공지능과 정보보안 | 인프라 보안

ML 기반 엔드포인트 보안

최종 사용자 디바이스 (서버, 데스크톱, 모바일 기기 등)를 악성코드와 같은 내부 및 외부 위협으로부터 보호하는 엔드포인트 보안 기술은 다음과 같이 발전해 왔다.



ML 기반 네트워크 보안

네트워크 위협의 경우 데이터의 양도 방대하고 위협의 종류와 그 패턴이 다양하여, 정상적인 네트워크 활동과 악성 활동을 정확히 구분하는 것이 상대적으로 어려운 분야로 평가되어 왔다. 비지도학습 기반 위협탐지와 지도학습 기반의 위협탐지로 구분할 수 있다.

비지도학습 기반	지도학습 기반
- 정상 상태의 Packet을 학습하여 비정상 행위를 탐지하는 방식 - 내부자 위협 탐지 : 사용자의 평소 행위를 학습하여 자신의 과거 행동패턴/Peer Group의 행동패턴과 다를 경우 탐지 - 제로데이 공격 탐지 : 이전에는 볼 수 없었던 새로운 공격 탐지	- 위협 패턴을 학습하여 탐지하는 방식 - 정오탐 분석: 보안 전문가가 위협 대응한 결과를 학습시켜 실시간으로 유입되는 위협에 대해 자동화된 탐지 - 위협 추론: 위협 지식을 그래프 형태로 학습하여 다양한 위협 시그널에 대해 종합적으로 평가하여 영향도를 추론

인공지능과 정보보안 | 취약점/리스크 관리

BAS (Breach And Attack Simulation)

위협에 선제적으로 대응하기 위해 조직의 리스크를 관리하는 방법으로는 침투 테스트(Penetration Testing), 취약성 평가(Vulnerability Assessment), 보안 감사(Security Audit), Threat Hunting 등이 있으며, 해당 분야 역시 AI와 자동화 기술을 활용하여 발전하고 있다. 그 중 BAS (Breach and Attack Simulation) 기술은 과거의 스캐너 기반의 Penetration 자동화 툴에서 한단계 진화한 것으로 평가받고 있다.

Real-Attack
vs. Simulation

조직이 당면한 잠재적인 위협(인텔리전스 기반 유입 가능성이 가장 높은 위협)에 대해 실제 인프라 운영에 영향 없이 주기적으로 안전하게 시뮬레이션할 수 있다.


Human-Led
vs. Automated

화이트 해커의 전문적 지식에 의존한 테스트 방법에서 자동화된 테스트 방법을 통해 효율적인 테스트 수행과 평가 결과의 일관성이 보장될 수 있다.

One-time
vs. Continuous

Penetration Testing이 특정 시점에서의 조직의 방어능력에 대한 검증이라면, BAS는 인프라에 변경사항이 발생할 때마다 취약점을 식별하여 지속적으로 관리할 수 있게 해준다.

솔루션 사례




<https://www.youtube.com/watch?v=MY3H7UwxQ8>

인공지능과 정보보안 | 인증

IAM (Identity and Access Management)

인증은 암호화 기술기반으로 보안분야에서 지속적으로 발전해 왔다. IT환경이 급변하면서 기존의 접근제어 방식으로는 적절히 보호하기 어려워 이용자의 사용패턴인식을 중심으로 AI 기술들이 접목되고 있는 추세이다.



한 개의 자격증명 세트를 사용해 조직의 인프라에서 통합으로 인증하는 방법 다수의 패스워드를 관리할 필요가 없어 자격증명의 분실/도난 위험 감소

웹사이트, 애플리케이션 또는 리소스에 대한 접근 권한을 부여받기 위해 사용자가 적어도 두 가지 이상의 확인 요소를 제공해야 하는 인증 방법

FIDO(Fast IDentity Online)인증은 인증 수단과 프로토콜을 분리 (단말기에서 인증 후, 전자서명값을 인증서버로 보내어 최종 인증)하는 방식 지문/홍채/얼굴/음성 등의 고유의 생체정보를 이용하는 생체인증과 함께 발전

물리보안 영역에서는 사용자의 모션 기반의 본인 인증(Gait Recognition), 디지털 보안 영역에서는 사용자의 사이트 이용패턴을 학습하여 인증하는 방식으로 발전 중


솔루션 사례



<https://www.youtube.com/watch?v=RE3JOdIOYIU>


Adversarial AI (적대적 공격)

보안솔루션만 진화하고 있는 것이 아니라 해커들도 공격의 정확성을 높이기 위해, 탐지를 더 잘 피하기 위해 AI화, 자동화 해 나가고 있는데, 특히 보안솔루션의 AI모델을 속이거나, AI모델 학습을 방해하는 방식의 적대적 공격이 보안의 큰 위협으로 다가오고 있다.



출처: https://itwiki.kr/w/적대적_스티커

Adversarial Attack (Adversarial AI) 기법은 크게 다음의 4종류로 나뉜다.



출처: <https://blog.lgcns.com/2191>


- Inversion Attack: 머신러닝 모델에 수많은 쿼리를 던진 후, 산출된 결과값을 분석해 모델 학습을 위해 사용된 데이터를 추출하는 공격
- Poisoning Attack: 의도적으로 악의적인 학습데이터를 주입해 머신러닝 모델을 망가뜨리는 공격
- Evasion Attack: 판단 대상이 될 데이터에 최소한의 변조를 가해 머신러닝 모델을 속이는 기법
- Model Extraction Attack: Inversion Attack이 공격대상 모델의 입력값과 결과값을 분석해 학습 데이터를 추출하는 공격이라면, Model Extraction Attack은 머신러닝 모델을 추출하는 공격이다. 주로 유료 머신러닝 모델 서비스를 탈취하거나 Evasion Attack과 같은 2차 공격에 활용하기 위해 사용될 수 있다.

Agentic AI 보안

The workflow of MCP.

MCP (Model Context Protocol)

자율 AI 에이전트의 확산으로 외부 도구 활용의 필요성이 높아짐에 따라 2024년 말 Anthropic은 AI 자동화를 위한 외부 도구의 정의·검색·호출을 표준화하기 위한 범용 프로토콜인 MCP를 제안하였다.



[그림] MCP 워크플로우

출처: <https://xinyi-hou.github.io/files/hou2025mcp.pdf>

Agentic AI의 보안위협

Agentic AI의 보안위협은 외부 도구, 파일, API, 데이터베이스를 직접 호출하고 실행하면서 발생하는 권한 오남용, 데이터 유출, 악성 지시 삽입, 도구 조작, 실행 오류 등의 위험이다.

분류	세부 위협	위협 내용
지시문 조작 및 실행 흐름 탈취	Prompt Injection, Indirect Prompt Injection	악성 프롬프트를 사용자 입력·문서·웹·도구 응답에 삽입하여 Agent의 판단과 실행 흐름을 조작
도구·MCP 서버 조작	Tool Poisoning, Tool Name Confusion, Tool Shadowing, Malicious Tool Server	악성 도구나 위조된 MCP 서버가 정상 도구처럼 동작하며 Agent의 도구 선택과 실행을 공격자 의도대로 유도
권한·인증정보 침해	Unauthorized Access, Token Theft / Account Takeover, Privilege Escalation	과도한 권한, 토큰 탈취, 취약한 접근통제로 인해 파일·DB·클라우드·업무시스템에 비인가 접근
민감정보 유출 및 실행환경 침해	Data Exfiltration, Command Injection, Sandbox Escape	Agent 도구 실행 과정에서 민감정보를 외부로 유출하거나 명령 실행·격리 우회로 시스템을 침해
공급망·운영 통제 실패	Installer Spoofing, Supply Chain Attack, Audit Failure, Runaway Automation	설치파일·라이브러리·플러그인 변조, 반복 자동화 오류, 감사 로그 부재로 운영 안정성과 추적성이 훼손

[그림] MCP 위협의 분류

보안특화 AI : Claude Mythos

Anthropic의 Claude Mythos는 취약점 탐지와 공격 가능성 분석 능력으로 주목받은 보안 특화 AI 모델로서 AI가 보안분석부터 취약점 발견, 공격 수행까지 자동화 가능성을 보여준 사례

인공지능 윤리

아실로마 AI 원칙

2017년 미국 캘리포니아에서 열린 아실로마 컨퍼런스에서 인공지능 관련 사회적 문제를 예방하기 위한 23개 원칙이 발표되었으며, 주요 내용은 다음과 같다.

- AI를 연구하는 목적은 인간에게 유익한 인공지능을 만드는 것이다.
- AI 시스템 때문에 피해가 발생할 경우, 그 이유가 무엇인지 정확히 알아야 한다.
- AI 시스템은 인간의 존엄성, 권리, 자유, 문화적 다양성과 공존할 수 있도록 설계/운영되어야 한다. (인간을 무시해서는 안 되고 피부색이나 종교, 신념 때문에 차별해서는 안 된다.)
- AI에 의해 경제적으로 풍요로운 결과가 나온다면 그 결과는 모든 인류와 함께 나누어야 한다.
- AI로 치명적인 살인무기를 만들어서는 안 되며 지구의 생명을 파괴해선 안 된다.



그림 출처: <https://news.sktelecom.com/117277>

AI 윤리기준

국내의 경우 2020년 12월 4차산업혁명위원회에서 'AI 윤리기준(사람이 중심이 되는 AI 윤리기준)'을 발표하였다. 인공지능이 지향하는 최고의 가치를 '인간성'으로 설정하고, 모든 인공지능은 '인간성을 위한 인공지능'이어야 함을 명시하고 있다.



출처: 사람이 중심이 되는 '인공지능(AI) 윤리기준'